Synthèse Bibliographique : Prévision frugale de la ressource solaire

Mini-projet

1. Concepts Fondamentaux : GHI, Irradiance et Photovoltaïque

1.1 Définitions de base

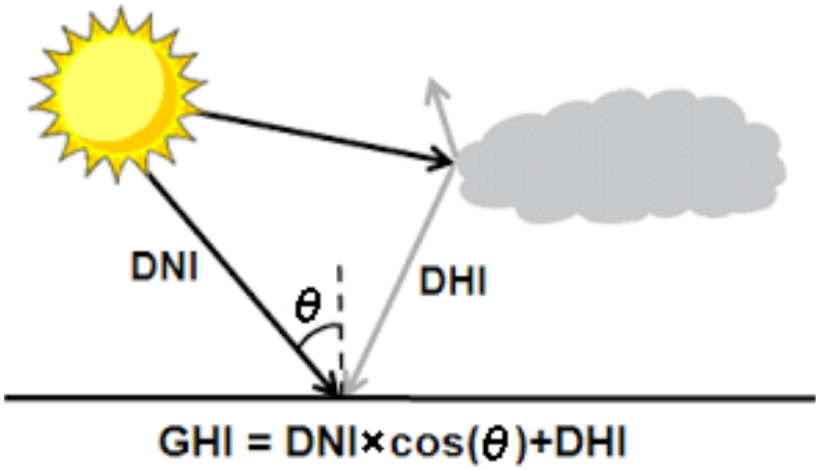
- **Irradiance (W/m²) :** Puissance du rayonnement électromagnétique solaire reçue par unité de surface. C'est une grandeur instantanée.
- **Irradiation (J/m² ou Wh/m²) :** Energie solaire reçue par unité de surface sur une période de temps donnée (on intègre l'irradiance sur un intervalle temporel).

  ($H = \int I(t)\,dt$, où H est l'irradiation et I(t) l'irradiance à l'instant t).

1.2 Le Rayonnement Global Horizontal (GHI)

Le **GHI** (Global Horizontal Irradiance) est utilisée pour estimer la production des panneaux photovoltaïques. Il correspond au rayonnement total mesuré sur une surface horizontale au sol.

Il se décompose selon l'équation suivante [6]:



- **DNI (Direct Normal Irradiance) :** C'est le rayonnement direct provenant du disque solaire, qui n'est pas intercepté par les nuages.
- **DHI (Diffuse Horizontal Irradiance) :** C'est le rayonnement dispersé et diffusé par l'atmosphère et qui traverse les nuages.
- **θz :** C'est l'angle zénithal (l'angle entre le soleil et le zénith, c'est-à-dire la verticale du lieu).

1.3 Intérêt et problématique du Photovoltaïque (PV)

Le principe du PV repose sur l'effet photoélectrique : des matériaux semi-conducteurs absorbent les photons du rayonnement solaire pour générer un courant électrique. Bien que décarbonée et abondante, l'énergie PV est intermittente. La puissance générée chute drastiquement au passage d'un nuage (phénomène dit "d'effet de rampe", pouvant atteindre 80 % de chute en quelques minutes [7]).

2. La Prévision et les Contraintes du Réseau (Cas de la Corse)

Sans prévision fiable du GHI, les gestionnaires de réseau doivent utiliser des réserves tournantes pour pallier les chutes soudaines. Le tableau ci-dessous compare les temps de réaction de différentes centrales.

Technologie	Temps de démarrage à froid	Temps de montée en puissance (Rampe)	Source
Moteur Diesel / Fioul / Gaz (Réserves)	2 à 5 minutes	~10 % à 20 % de Pnom / min	Entso-E / RTE [8]
Turbine à Gaz à Cycle Simple (TAC)	10 à 15 minutes	~10 % à 15 % / min	IEA
Centrale Nucléaire (Téléréglage)	Plusieurs heures	~1 % à 5 % / min (contraintes)	AIEA

Le nucléaire, bien que décarboné, est trop lent pour compenser le passage d'un nuage. De plus, la Corse est un système électrique isolé, non connecté au parc nucléaire métropolitain, et ses ressources hydrauliques sont limitées. Le réseau doit donc s'appuyer sur des centrales thermiques fortement émettrices en CO_2 [8].

2.1 Pourquoi prévoir ?

Prévoir le GHI permet d'anticiper la production PV. Cela est vital pour :

1. L'équilibrage du réseau (éviter les black-outs ou les surtensions).
2. L'optimisation économique (minimisation des pénalités de déséquilibre).
3. La gestion optimisée du stockage associé aux centrales.

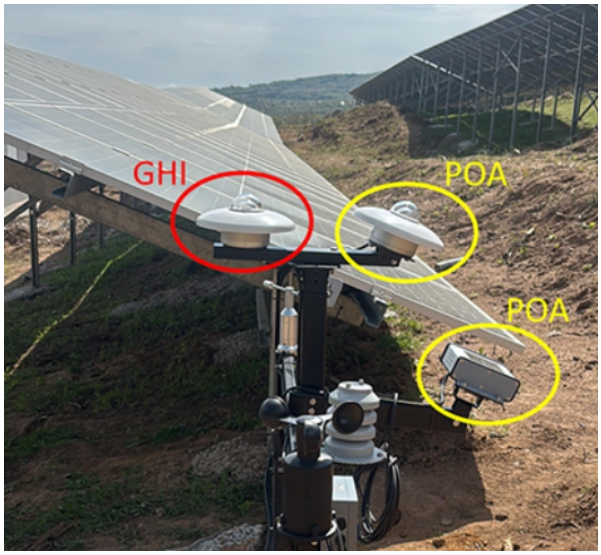
2.2. Quelles méthodes pour quels horizons ?

Le choix d'un modèle de prévision dépend de l'horizon de temps visé donc l'échelle de temps.

- **Très court terme (0 à 6 heures)** : Les phénomènes locaux (déplacement de nuages) dominent. Les modèles statistiques basés sur l'historique des données (AR, ARIMA, Machine Learning) ou l'imagerie du ciel (Sky Imagers) sont les plus performants. C'est l'horizon (1h) visé par ce projet.
- **Court terme (6 heures à 72 heures)** : Les modèles qui résolvent les équations de la mécanique des fluides de l'atmosphère, deviennent indispensables.
- **Moyen/Long terme (au-delà de 3 jours)** : On s'appuie sur la climatologie et les statistiques saisonnières.

3. Séries Temporelles et Mesures In-Situ pour le GHI

3.1. Mesure In-Situ : Appareils et Principes



La mesure du GHI au sol s'effectue principalement à l'aide d'un **pyranomètre**. Il en existe deux types majeurs :

- **Les pyranomètres à thermopile** : Ils mesurent la différence de température entre une surface noire (absorbant le rayonnement) et une référence. Ils offrent une réponse spectrale large et précise, ce sont les standards de l'Organisation Météorologique Mondiale (OMM).
- **Les pyranomètres à photodiode (silicium)** : Moins chers, ils mesurent un courant généré par l'irradiance. Ils sont plus rapides mais restreints à la bande spectrale du silicium.

3.2 Séries Temporelles et Modèles de Référence

Une série temporelle est une suite d'observations $(y_1, y_2, \ldots, y_t)$ mesurées à des pas de temps réguliers (time step). Pour la prévision, on cherche à estimer y_{t+h} où h est l'horizon de prévision.

Les modèles de base (Benchmarks) [4, p. 750] :

- **La Persistance** : Le modèle le plus frugal. Il postule que la valeur à l'instant futur sera égale à la valeur présente : $\widehat{GHI}_{t+h} = GHI_t$. Très efficace pour des horizons très courts (< 15 min), mais souffre d'un défaut majeur : il ne prend pas en compte la course naturelle du soleil (la nuit, la persistance est fausse à l'aube).
- **La Persistance Intelligente (Smart Persistence)** : Pour pallier le problème de la course du soleil, on retire la composante déterministe en utilisant un modèle de ciel clair (Clear Sky Model).

3.3. Modèle de Ciel Clair

Un modèle de ciel clair, comme le modèle simplifié de *Solis* [1, p. 759], estime le GHI théorique si le ciel était parfaitement sans nuages, en fonction des paramètres astronomiques et atmosphériques (aérosols, vapeur d'eau).

Pour obtenir une série temporelle stationnaire (désaisonnalisée), on calcule l'**indice de ciel clair** :

$$k_t = \frac{GHI_{\text{mesure}}}{GHI_{cs}}$$

La *smart persistence* consiste alors à prédire l'indice de ciel clair par persistance, puis à remultiplier par le modèle de ciel clair futur :

$$\widehat{GHI}_{t+h} = k_t \times GHI_{cs,t+h}$$

4. Modélisation Statistique et Machine Learning Frugal

4.1. Régression Linéaire

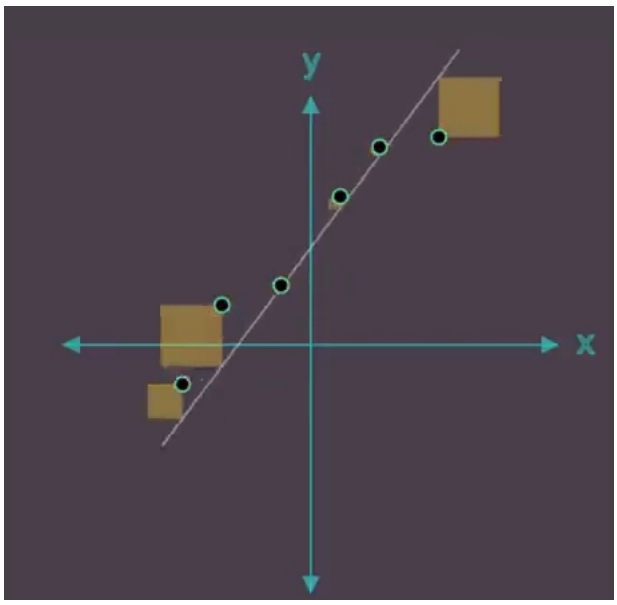
Le but de cette méthode est de trouver la meilleure droite de régression de la forme :

$$Y = X\beta + \epsilon$$

avec bêta les coefficients à trouver et epsilon l'erreur, pour prédire le futur à partir des données qu'on aura récoltées par le passé !

Pour trouver bêta, on utilise les moindres carrés, donc on minimise l'aire des carrés en jaune.

:



Et on obtient une expression simple matricielle de beta :

$$\hat{\beta} = (X^T X)^{-1} X^T Y$$

Problème: Le mouvement des nuages, la température de l'air etc...,induisent des variations brusques et donc la régression est peu fiable. On doit donc améliorer le modèle.

4.2 Extreme Learning Machine (ELM)

Pour expliquer le fonctionnement de l'ELM, on va partir de l'objectif initial : prédire le futur à partir des données passées. Donc on part d'un vecteur $\mathbf{x} = [GHI_t, GHI_{t-1}, GHI_{t-2}]$ et on essaie de prédire GHI_{t+1}.

Étape 1 : On génère des vecteurs de poids aléatoires $\mathbf{w}_i$, qui quantifient l'importance des données historiques passées, et des b_i qui sont des seuils de décalage, des biais. On a donc $\mathbf{w}_i \cdot \mathbf{x} + b_i$.

Étape 2 : On introduit de la non-linéarité. On ne fait pas la même erreur que la régression linéaire classique, car on sait pertinemment que les données sont de formes en tout genre. On introduit donc une non-linéarité maîtrisée grâce à une fonction sigmoïde g par exemple. On obtient donc la matrice H avec $h_i = g(\mathbf{w}_i \cdot \mathbf{x} + b_i)$, qui est la matrice de la couche cachée. On crée ainsi plein de courbes de données différentes.

Étape 3 : Prévisions. En réalité, le but est d'entraîner notre modèle. Donc, on connaît déjà les réponses. On les a dans une matrice T. La prédiction est la somme des $\beta \cdot h_i$, donc matriciellement $H\beta = T$, la sortie est donc modulée par β. C'est donc β qu'on va modifier pour affiner notre modèle ; il va contenir les poids qu'on va affecter aux différentes courbes et c'est ici qu'on va faire une régression linéaire. On obtient donc β par la pseudo-inverse

Bibliographie

[1] P. Ineichen, "A broadband simplified version of the Solis clear sky model," *Solar Energy*, vol. 82, no. 8, pp. 758–762, 2008.

[2] G.-B. Huang, Q.-Y. Zhu, et C.-K. Siew, "Extreme learning machine: Theory and applications," *Neurocomputing*, vol. 70, no. 1–3, pp. 489–501, 2006.

[3] N.-Y. Liang, G.-B. Huang, P. Saratchandran, et N. Sundararajan, "A fast and accurate online sequential learning algorithm for feedforward networks," *IEEE Transactions on Neural Networks*, vol. 17, no. 6, pp. 1411–1423, 2006.

[4] C. Voyant *et al.*, "Benchmarks for solar radiation time series forecasting," *Renewable Energy*, vol. 191, pp. 747–762, 2022.

[5] R. J. Hyndman et G. Athanasopoulos, *Forecasting: Principles and Practice*, 3rd edition, OTexts, 2021.

[6] M. K. Boutahir *et al.*, "Effect of Feature Selection on the Prediction of Direct Normal Irradiance," *Big Data Mining and Analytics*, vol. 5, no. 4, pp. 309–317, Dec. 2022.

[7] C. Voyant *et al.*, "Machine learning for solar radiation forecasting: A review," *Renewable Energy*, vol. 114, pp. 1121–1145, 2017.

[8] K. Solaun et E. Cerdá, "Impacts of climate change on solar thermal electricity generation in Spain," National Renewable Energy Laboratory (NREL), 2019.