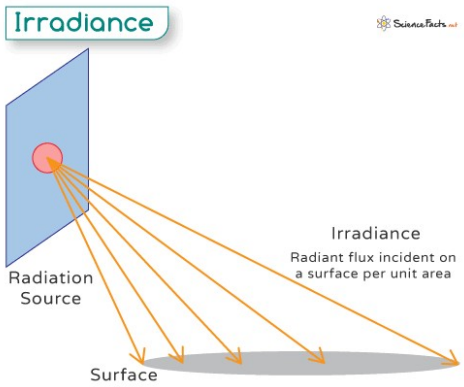
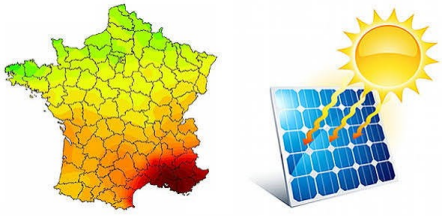
Prévision frugale de la ressource solaire : modèle de ciel clair, Extreme Learning Machine (ELM) et apprentissage en ligne

Irradiance : Aussi appelée éclairement énergétique, c'est une mesure surfacique de la puissance d'un rayonnement électromagnétique (W/m²).



Irradiation solaire : Par rapport à l'irradiance, elle correspond à l'énergie solaire reçue sur une surface pour une période donnée, ce n'est donc plus une puissance (J/m²). On la mesure à l'aide d'un radiomètre ou d'un albédomètre.



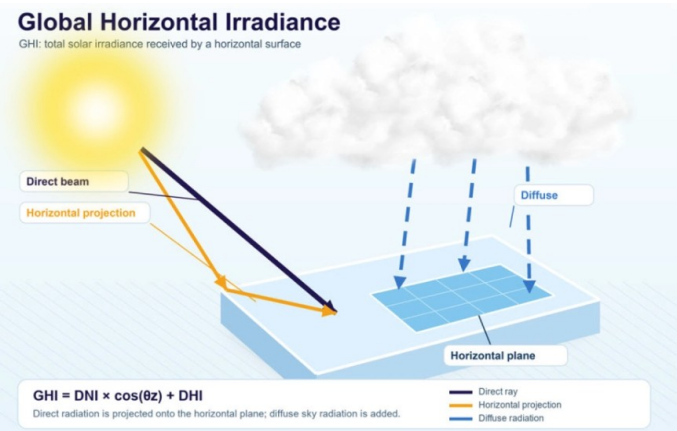
Dans le domaine de l'énergie solaire, nous devons mesurer l'ensoleillement pour déterminer la quantité d'énergie produite par nos panneaux. Quatre principaux types d'irradiance solaire sont utilisés pour la surveillance du système photovoltaïque :

- POA (Plan de réseau)
- GHI (irradiance horizontale globale)
- DHI (irradiance horizontale diffuse)
- DNI (irradiance normale directe)

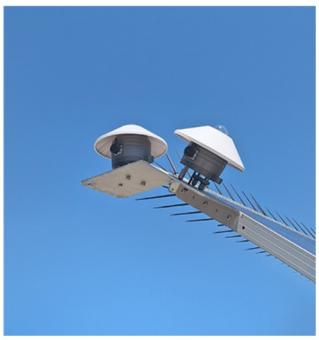
L'objectif d'avoir une variété de types de mesures de l'ensoleillement est de pouvoir adopter différents points de vue vis-à-vis de l'efficacité d'un panneau solaire.

POA : Il correspond à la puissance totale solaire reçue par un panneau, qu'elle soit reçue directement de la part du soleil, qu'elle soit diffuse depuis le ciel ou bien réfléchie par l'environnement.

GHI (Global Horizontal Irradiance) : Désigne une puissance par unité de surface (W/m²), plus exactement la puissance solaire totale reçue sur une surface **plane**. Il ne comprend pas la lumière réfléchie par l'environnement. On peut le mesurer à l'aide d'un pyranomètre à thermopile.



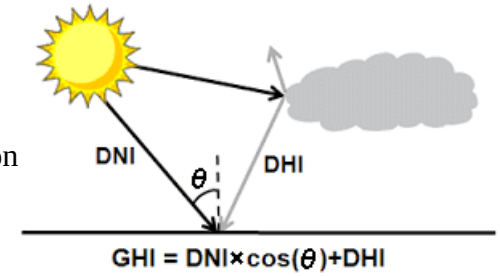




DHI : Il est relié à la composante diffuse du GHI, ie. qui ne provient pas directement du soleil. On peut donc l'assimiler à la puissance solaire que reçoit le panneau lorsque le ciel est totalement couvert de nuages. On peut le mesurer en ombrageant le pyranomètre de sorte à bloquer la lumière directe venant du soleil.

DNI : C'est justement la puissance lumineuse directe venant du soleil. On le mesure à l'aide des pyrhéliomètre qui suit constamment la direction du soleil de sorte à capter toujours directement son rayonnement.

Revenons au GHI, on le calcule de la manière suivante :

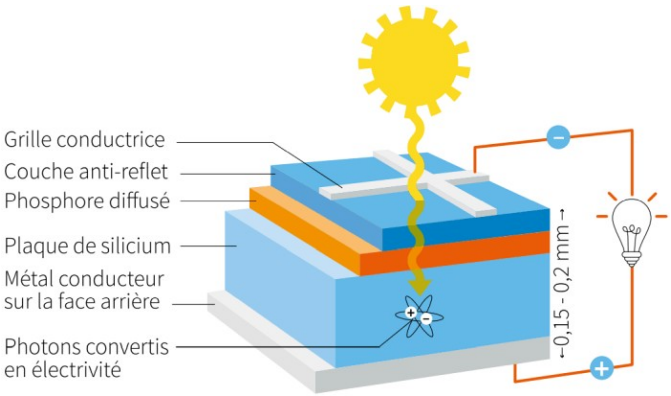


La projection à l'aide de l'angle theta permet de quantifier l'étalement des rayons du soleil lorsqu'il s'approche de l'horizon pour un observateur terreste : theta = 0° implique pas d'étalement et donc que l'entièreté du DNI est transférée au GHI.

Autre formule intéressante, DHI = POA/cos(theta), donc le POA correspond à la projection horizontale du DHI.

Système PV : PV pour photovoltaïque.

Les panneaux solaires sont composés de cellules semi-conductrices (souvent du silicium). Les cellules contiennent deux couches de silicium dopés, une à l'aide de phosphore du sorte à créer un surplus d'électrons, et l'autre à l'aide de bore pour créer un déficit d'électrons. Le choc des photons émis par le soleil sur le panneau permet de créer un courant électrique ordonné que l'on convertit ensuite (onduleur…) en courant alternatif utilisable par les installations domestiques.



Le PR (Performance Ratio) d'un système photovoltaïque est l'indicateur clé qui mesure l'efficacité réelle d'une installation par rapport à sa production théorique maximale.

$$PR = \frac{\text{Production réelle (kWh)}}{\text{Production théorique (kWh)}}$$

Un bon système solaire bien conçu et entretenu atteint généralement un PR compris entre 75 % et 85 %.

Pourquoi le photovoltaïque ?

L'objectif est de limiter l'usage des énergies fossiles. L'énergie solaire est renouvelable, et, bien que L'année dernière, la production mondiale de panneaux PV a généré environ 400 millions de tonnes de CO2, cette pollution est principalement due au fait que la majorité des usines sont situées en Asie, où l'électricité provient encore largement de centrales au charbon, d'autant plus qu'en France, un panneau solaire "rembourse" sa dette carbone en 1 à 3 ans seulement. D'un point de vue économique, des particuliers installent des panneaux solaires de réduire sa facture d'énergie de 30 à 70 % (l'amortissement de l'investissement s'observe entre 6 et 12 ans après l'installation).

Prévisions PV/GHI

Une utilisation efficace des sources d'énergie fluctuantes nécessite des prévisions fiables pour les stratégies de gestion et d'exploitation de sorte à ne pas la gaspiller car cette énergie est volatile (dans le sens où son stockage est une contrainte).

Deux méthodes sont généralement retenues : une passant par l'analyse de données existantes et de séries chronologiques historiques de l'irradiation globale, c'est donc une approche statistique et empirique qui parie sur la reproductibilité d'événements en connaissant leurs conditions d'apparition. L'autre méthode consiste à prévoir les données futures à l'aide de l'imagerie (colorimétrie du ciel, présence et direction des nuages…) et de l'outil numérique (NWP pour Numerical Weather Prediction).

La première méthode s'attache à prévoir une irradiation solaire moyenne et localisée sur une période et est adaptée à une prévision à court terme (1h à 5h d'avance), la deuxième tente plutôt de calculer l'irradiation globale à un instant t du futur et est efficace pour des prévisions à long terme (plus d'un jour d'avance) pour lesquelles la variabilité et l'aléatoire des mouvements des nuages influe moins.

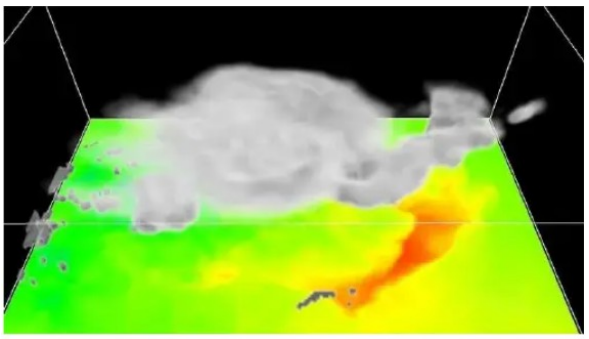
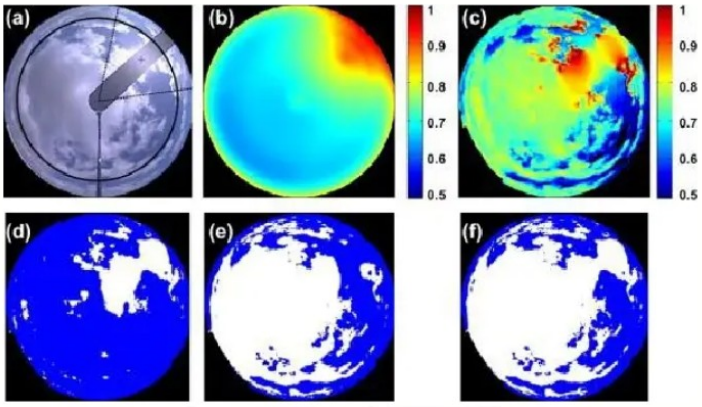


Illustration 3D d'après le modèle NWP

Actuellement, la prévision physique est principalement effectuée à l'aide de la prévision numérique du temps (NWP) et des observations des nuages par satellite ou par Total Sky Imager (TSI). La PNT fournit des informations jusqu'à plusieurs jours à l'avance, mais il existe des biais importants et des erreurs aléatoires dans les estimations de l'irradiance. La résolution spatiale de la NWP est grossière, avec un pixel de 100 km2 pour les plus précises.

Plus récemment est apparue l'usage de réseaux de neurones artificiels (ANN), ils utilisent des bases de données de sorte à mettre efficacement en œuvre la première méthode présentée précedemment.



Images d'après un TSI

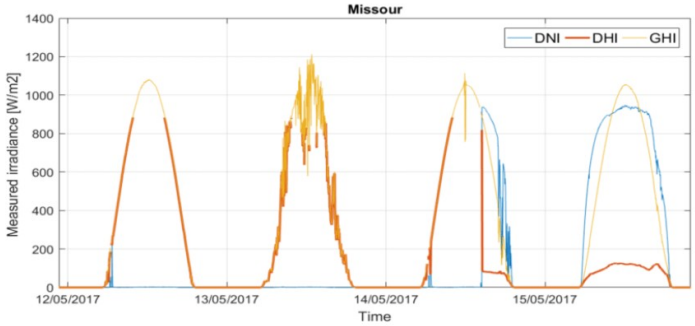
Généralement, on combine tous ces modèles de sorte à avoir une prédiction la plus fiable possible à court **et** long terme. Le choix des modèles de prévision appropriés dépend de l'horizon de prévision et des données disponibles

Mesures in-situ/séries temporelles pour le GHI

Le principe utilisé est celui d'une thermopile (pyranomètre cité plus haut) : le rayonnement solaire arrive sur une surface noire, elle absorbe le rayonnement et chauffe, la différence de température crée une tension électrique puis cette tension est convertie en irradiance.

Différents modèles peuvent être abordés :

1. Modèle de persistance → on considère que le ciel ne change pas, utile sur les très courts horizons, GHI(t+delta_t) = GHI(t)



2. Modèle statistique → le nouveau GHI est uniquement calculé à partir des anciennes valeurs de GHI en s'aidant de données préexistantes

3. Machine learning → on donne au modèle l'ensemble des anciennes valeurs de GHI ainsi que des valeurs sur la météo actuelle et la géométrie de la situation (orientation du panneau par rapport au soleil…)

Le choix du pas de mesure (time step) est important et dépend de l'effet attendu.

1 seconde à 1 minute :
Recherche scientifique, contrôle de la qualité de l'énergie injectée sur le réseau, détection précise de passages nuageux. Cela requiert cependant de manier des quantités massives de données, et cela peut ralentir le processus de prévision

5 à 15 minutes :
C'est le pas de temps de référence sur les centrales photovoltaïques modernes pour calculer le PR (Performance Ratio), comparer la production réelle aux simulations et alimenter les algorithmes de prévision à très court terme. Cela permet de limiter l'accumulation de données, et un lissage des courbes obtenues permet de s'approcher de la réalité

1 heure :
Utilisation classique pour les bilans énergétiques à long terme (données météo) et les études de faisabilité de projets solaires. Bien que d'un point de vue des données, on soit ici très léger, cela peut masquer la dynamique réelle de l'irradiance

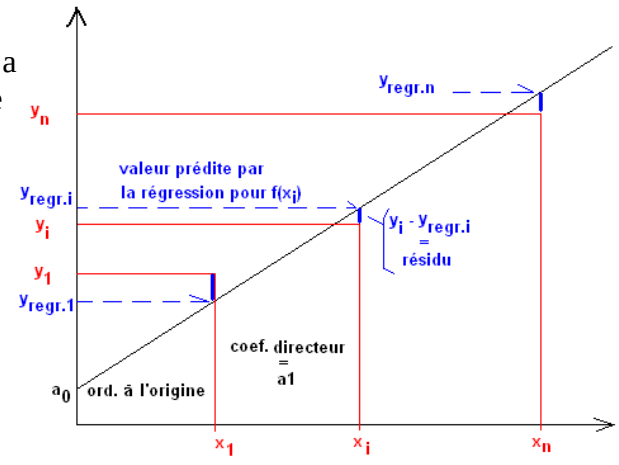
L'horizon correspond à durée s'écoulant entre maintenant et la prochaine valeur prévue.

Horizon	Échelle	Informations utilisées	Application
Nowcasting	secondes → ~30 min	GHI récent, caméra ciel, satellite	gestion instantanée
Très court terme	~30 min → 2 h	GHI + nuages + satellite	batteries, réseau
Court terme	2 → 6 h	satellite + météo + GHI	gestion de centrale
Intraday	6 → 24 h	météo + GHI	gestion du réseau
Day-ahead	24 → 48 h	NWP + modèle solaire	marché électrique
Moyen terme	2 → 7 jours	NWP + ensembles	planification
Long terme	semaines → mois	climatologie + météo	planification énergétique
Très long terme	années → décennies	climatologie + modèles climatiques	dimensionnement / investissement

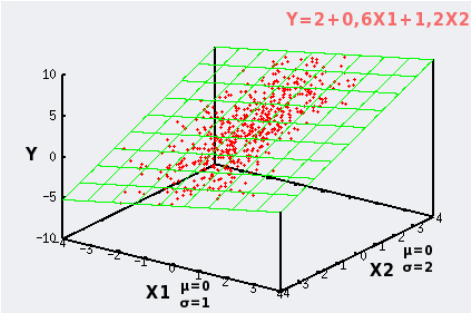
Méthodes numériques :

Régression linéaire → objectif = trouver les paramètres a et b d'une droites d'équations y=ax+b qui permettent de faire corréler les paramètres x et y.

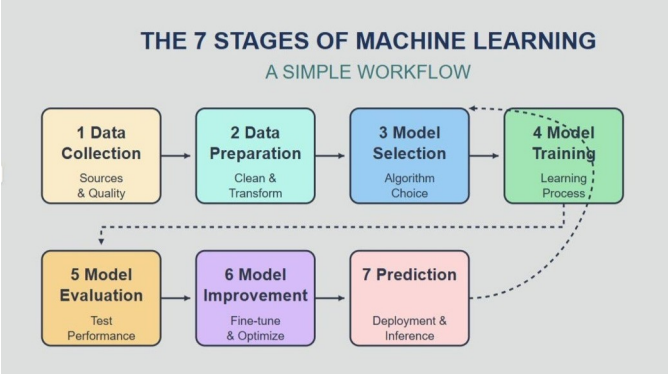
Pour cela, on utilise la méthode des moindres carrés qui consiste à choisir a et b de sorte à réduire au maximum la somme des carrés des résidus (ie. la différence entre valeur prédite et valeur réelle y pour un x donné)



En pratique on la met en œuvre en dimension > 2 :



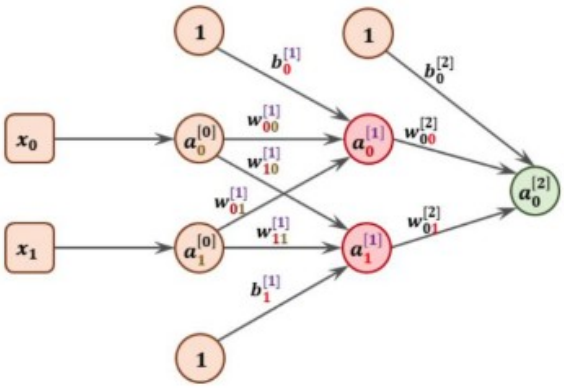
Machine learning :



Le machine learning est un pan du domaine de l'intelligence artificielle, il en existe différents types : apprentissage supervisé (on donne des données connues à un réseau de neurone qui a alors une tâche bien précise à accomplir), apprentissage non supervisé (on donne des données que l'on n'a pas triées au préalable et le rôle du réseau est de les ranger), apprentissage par renforcement (on apprend au réseau à effectuer une tâche en le récompensant/pénalisant selon que ses actions sont bénéfiques ou néfastes au but voulu.

Soit un réseau de neurones à trois couches :

- Couche d'entrée à 2 neurones : $X=(x_0,x_1)$.
- Couche cachée à 2 neurones, de fonction d'activation $f^{[1]}$.
- Couche de sortie à 1 neurone : $Y=(y_0)$ le vecteur des sorties, de fonction d'activation $f^{[2]}$.



Couche [0] :

$$a_0^{[0]}=x_0$$
$$a_1^{[0]}=x_1$$

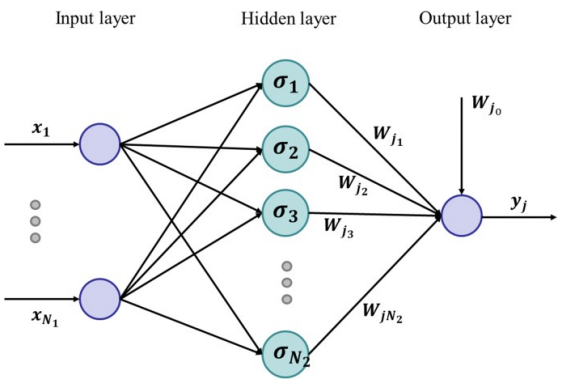
Couche [1] :

$$a_0^{[1]}=f^{[1]}\left(w_{00}^{[1]}.a_0^{[0]}+w_{01}^{[1]}.a_1^{[0]}+b_0^{[1]}\right)$$
$$a_1^{[1]}=f^{[1]}\left(w_{10}^{[1]}.a_0^{[0]}+w_{11}^{[1]}.a_1^{[0]}+b_1^{[1]}\right)$$

Couche [2] :

$$a_0^{[2]}=f^{[2]}\left(w_{00}^{[2]}.a_0^{[1]}+w_{01}^{[2]}.a_1^{[1]}+b_0^{[2]}\right)$$

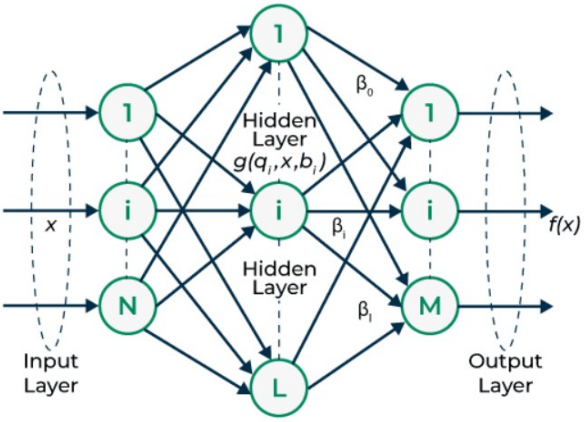
Extreme learning machine (ELM) : Cela désigne un type de réseau de neurone avec **une seule couche cachée**. Le terme « extreme » se rapporte au fait que les poids entre l'entrée et la couche cachée sont choisis aléatoirement, sans être entraînés.



Équations et principe : Les poids et les biais entre la couche d'entrée et la couche cachée sont générés de manière aléatoire au début et ne sont jamais modifiés pendant l'apprentissage.

Seuls les poids de la couche de sortie sont calculés. Ce calcul se fait en une seule étape mathématique directe (via une « inversion de matrice » ie. le pseudo-inverse de Moore-Penrose),

sans aucune boucle ni descente de gradient, **ce qui accélère grandement le temps de calcul, car il n'y a pas de dépendance entre les poids d'entrée et de sortie comme dans la procédure d'entraînement par rétropropagation.** L'entraînement est des milliers de fois plus rapide que les réseaux traditionnels.



La sortie s'écrit :

$$f_L(x) = \sum_{i=1}^{L} \beta_i g_i(x) = \sum_{i=1}^{L} \beta_i g(w_i * x_j + b_i), j = 1, ..., N$$

On part d'un jeu de N couples (x,t) de données (x et t sont des vecteurs à L composantes)
Les w_i sont des poids, les b_i sont des biais, et g est la fonction d'activation préalablement choisie.

On cherche à choisir les $beta_i$ de sorte à minimiser une fonction coût qui par exemple pourrait être la somme des carrés des résidus de la réponse du réseau aux entrées x avec les résultats attendus y. Ainsi on obtient un réseau avec un comportement proche de celui attendu avec peu de temps de calcul. A remarquer que la performance dépend aussi du jeu de poids aléatoirement choisi initialement, donc que les résultats du modèle dépendent de son initialisation.

$$H = \begin{bmatrix} g(w_1 * x_1 + b_1) & \dots & g(w_L * x_1 + b_L) \\ \vdots & \dots & \vdots \\ g(w_1 * x_N + b_1) & \dots & g(w_L * x_N + b_L) \end{bmatrix}_{N \times L}$$

$$\beta = \begin{bmatrix} \beta_1^T \\ \vdots \\ \beta_L^T \end{bmatrix}_{L \times m} \qquad T = \begin{bmatrix} t_1^T \\ \vdots \\ t_N^T \end{bmatrix}_{N \times m}$$

Concrètement, comme la sortie $Y = [y_1, y_2, \dots, y_N]$ (en fait $y_i = f_L(x)$ pour j=i) vérifie $T = H\beta$
il suffit d'imposer Y=T où $T = [t_1, t_2, \dots, t_N]$ est le vecteur d'entraînement, ce qui donne des conditions sur le vecteur beta. Le pseudo-inverse de Moore-Penrose permet de déterminer une bonne solution au problème : $\hat{\beta} = H^{\dagger}T$